Lựa chọn dataset cho bài toán Propensity

Tháng 11, 2026

Mục lục

1. Mục tiêu và phương pháp

2. Đánh giá dataset

3. Kết luận và hướng phát triển

Task tuần và tiêu chí lựa chọn

Task cần hoàn thành

- Chọn ba dataset và thực hiện EDA cơ bản.
- Ưu tiên lịch sử dài và feature đa dạng.
- Nghiên cứu propensity và domain đã chọn.
- Giải thích vì sao giữ hoặc loại từng dataset.

Điều kiện cho time-window propensity

1. Lịch sử dataset ít nhất 12 tháng.
2. Entity xuất hiện nhiều lần, qua nhiều tháng.
3. Feature có sẵn trước snapshot.
4. Nhãn được tạo từ hành vi sau snapshot.

Propensity trong bài toán mua hàng

Câu hỏi mô hình

Với khách hàng tại thời điểm t, ước lượng xác suất thực hiện hành vi mục tiêu trong tương lai.

$$\hat{p}_{i,t} = P(y_{i,t} = 1 \mid X_{i,t-12m:t})$$

Ví dụ

- Mua lại trong 30 ngày.
- Mua ngành hàng cụ thể.
- Phản hồi campaign hoặc sử dụng coupon.

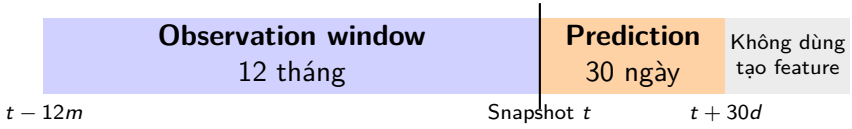
Dataset cần thể hiện

- Hành vi lặp lại của cùng entity.
- Trình tự thời gian đủ dài.
- Feature chỉ dùng thông tin trước t.
- Nhãn hoàn toàn sau t.

Rủi ro: data leakage nếu feature nhìn thấy tương lai.

Nguồn: Wheat & Morrison (1990); scikit-learn Time Series Split.

Observation window và prediction window



Feature trước snapshot

Recency, basket, tháng hoạt động, chi tiêu, khoảng cách mua, category, độ nhạy giảm giá.

Nhãn sau snapshot

$y = 1$ nếu household mua category mục tiêu trong 30 ngày; ngược lại $y = 0$.

100 giao dịch trong một ngày khác với 100 giao dịch trải dài 12 tháng.

Khung EDA dùng chung

Temporal

- Ngày đầu–cuối
- Số tháng quan sát
- Tháng thiếu
- Records theo tháng

Entity history

- Số entity duy nhất
- Tỷ lệ lặp lại
- Hoạt động từ 2 tháng
- First–last span
- Entity-month coverage

Quality

- Missing, duplicate

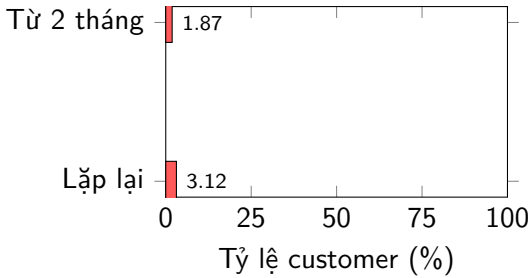
Nguyên tắc

Cùng một bộ hàm EDA và tiêu chí giúp so sánh dataset công bằng, đồng thời làm nền tảng package tái sử dụng.

Các dataset và target có thể xây dựng

Dataset	Dữ liệu có sẵn	Target propensity khả thi
Brazilian Olist	Customer, order, item, payment, review, product, seller	Mua lại trong 30/60/90 ngày?
H&M	Customer, article, giao dịch, giá, kênh bán	Mua lại, mua category hoặc dùng online?
Dunnhumby	Household, basket, product, promotion, campaign, coupon, demographic	Mua category hoặc phản hồi marketing?
RetailRocket	Visitor, view, add-to-cart, transaction, item properties	Chuyển đổi sau chuỗi hành vi?

Brazilian Olist: khách hàng ít quay lại



- **Lặp lại:** có nhiều hơn một order, kể cả khi các order nằm trong cùng tháng.
- **Từ 2 tháng:** phát sinh order trong ít nhất hai tháng khác nhau.

99.441 orders

96.096 customer duy nhất

25 tháng lịch sử toàn dataset

Kết luận: loại

- 96,88% customer chỉ có một order.
- Chỉ 3,12% customer phát sinh nhiều hơn một order.
- Chỉ 1,87% customer hoạt động trong ít nhất hai tháng.

Trong bộ dữ liệu e-commerce Olist, `order_purchase_timestamp` chỉ ghi nhận thời điểm đặt hàng. Dataset không có lịch sử hành vi trước khi mua.

Với phần lớn customer chỉ có một order, không đủ lịch sử trước snapshot để tạo feature hành vi và nhãn mua trong tương lai.

Nguồn: EDA cục bộ từ `olist_orders_dataset.csv` và `olist_customers_dataset.csv`.

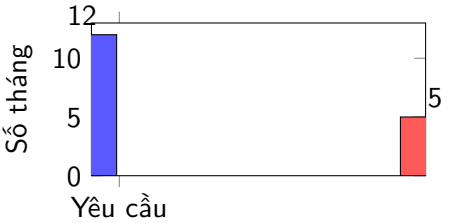
RetailRocket: nhiều event nhưng lịch sử ngắn

2,76 triệu event

1,41 triệu visitor

28,85% visitor lặp lại

4,66% visitor hoạt động từ 2 tháng



Kết luận: loại. 03/05/2015–18/09/2015 không đủ observation window 12 tháng.

Nguồn: EDA cục bộ: events.csv;

H&M: quy mô lớn, feature sản phẩm phong phú

31,79 triệu dòng giao dịch

1,36 triệu customer

25 tháng 09/2018–09/2020

90,35% customer lặp lại

63,92% hoạt động từ 2 tháng

Điểm mạnh

- Article có thuộc tính category.
- Giá, sales channel .

Hạn chế

- Entity-month coverage 18,29%.
- 9,36% dòng giao dịch trùng theo các cột hiện có.
- Một số customer feature thiếu khoảng 65%.

Nguồn: EDA cục bộ: transactions_train.csv, customers.csv, articles.csv.

Dunnhumby: lịch sử household dày

2.500 household

276.484 basket / 2,60 triệu item-lines

24 tháng 711 ngày; không thiếu tháng

99,88% household lặp lại

75,44% entity-month coverage

Điểm mạnh

- 99,76% household hoạt động từ 2 tháng.
- Trung bình 110,6 basket/household.
- Có product hierarchy, discount, campaign, coupon, demographic (một phần).

Hạn chế: ít household; `DAY` là ngày tương đối, không phải ngày lịch thật.

Giữ làm ứng viên chính.

Nguồn: Dunnhumby The Complete Journey; EDA cục bộ từ 8 bảng CSV.

So sánh hai dataset đạt điều kiện tối thiểu

Tiêu chí	H&M	Dunnhumby	Nhận xét
Lịch sử	25 tháng	24 tháng	Đều đạt 12 tháng
Entity	1,36 triệu customer	2.500 household	H&M mạnh về scale
Entity lặp lại	90,35%	99,88%	Dunnhumby đồng đều hơn
Hoạt động từ 2 tháng	63,92%	99,76%	Dunnhumby tốt hơn
Entity-month coverage	18,29%	75,44%	Dunnhumby dày hơn
Feature	Article, giá, channel	Basket, discount, campaign, coupon	Dunnhumby gần marketing propensity
Rủi ro	Sparse history, duplicate, missing	Ít household, ngày tương đối	Hai mục tiêu benchmark khác nhau

Quyết định dataset và domain

Đề xuất chính: Dunnhumby – The Complete Journey

- Đủ lịch sử cho observation window 12 tháng.
- Hầu hết household lặp lại qua nhiều tháng.
- Campaign và coupon tạo bài toán nghiệp vụ rõ.
- Quy mô phù hợp hoàn thiện pipeline trước khi scale sang H&M.

Bài toán đề xuất trên Dunnhumby

Target

Tại snapshot tháng t, dự đoán household có mua ngành hàng mục tiêu trong n ngày tiếp theo hay không.

$$y_{i,t} = \mathbb{1}\{\text{mua category trong } (t, t + n_{(}day)]\}$$

Feature trong 12 tháng

- RFM cấp household/category.
- Số tháng hoạt động, khoảng cách mua.
- Tỷ trọng chi tiêu theo department, brand, category.
- Discount, coupon, campaign.
- Demographic.

Dunnhumby: cấu trúc và quy mô dữ liệu

Cấu trúc dữ liệu

Bảng	Số dòng	Cột
Transaction data	2.595.732	12
Product	92.353	7
Household demographic	801	8
Campaign description	30	4
Household–campaign	7.208	3
Coupon definition	124.548	3
Coupon redemption	2.318	4
Causal data	36.786.524	5

Thống kê hỗ trợ Feature Engineering

Chỉ số	Giá trị
Sản phẩm	92.353
Campaign	30
Household được nhắm đến	1.584
Lượt redeem coupon	2.318
Household redeem	434
Household có demographic	801

Tổng quan

8 bảng – 39,6 triệu dòng

32 cột theo thống kê ban đầu

Nguồn: Thống kê trực tiếp từ 8 bảng CSV của Dunnhumby The Complete Journey.

Một dòng trong transaction data có ý nghĩa gì?

Đơn vị quan sát

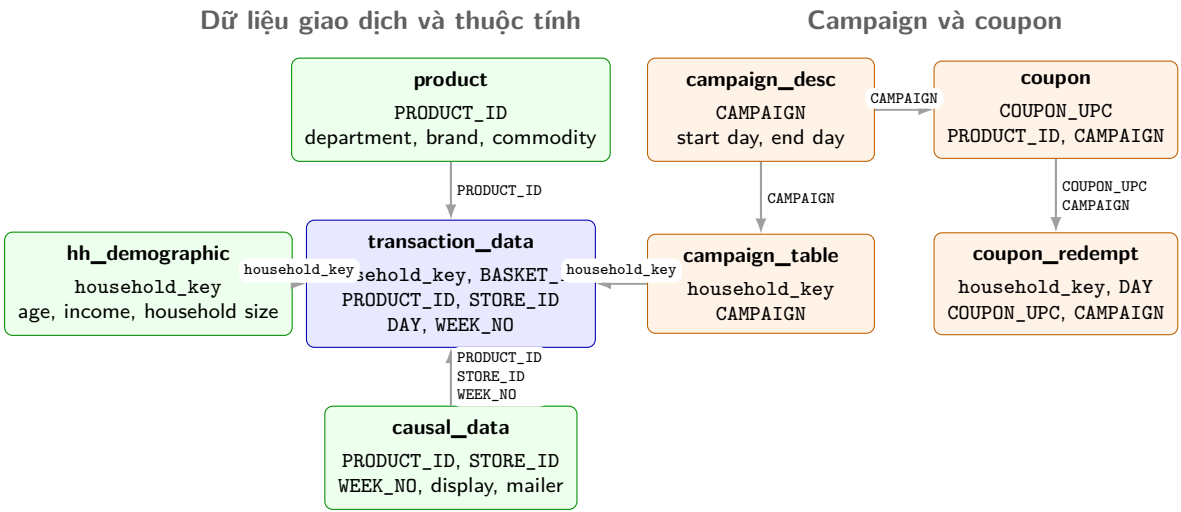
Mỗi dòng biểu diễn **một sản phẩm trong một basket**. Một basket chứa nhiều sản phẩm nên cùng một `BASKET_ID` xuất hiện trên nhiều dòng.

Ví dụ từ dữ liệu thực tế

household	BASKET_ID	DAY	PRODUCT_ID	QUANTITY	SALES_VALUE
2375	26984851472	1	1004906	1	1,39
2375	26984851472	1	1033142	1	0,82
2375	26984851472	1	1036325	1	0,99
2375	26984851472	1	1082185	1	1,21

Nguồn: Ví dụ trực tiếp từ `transaction_data.csv`.

Mối quan hệ giữa các bảng Dunnhumby



Nguồn: Khóa liên kết được xác định từ schema của 8 bảng CSV.

Các nhóm feature đã có trong Dunnhumby

1. Định danh và thời gian giao dịch
`household_key`, `BASKET_ID`, `DAY`, `WEEK_NO`, `TRANS_TIME`, `STORE_ID`.

2. Giá trị và số lượng mua
`PRODUCT_ID`, `QUANTITY`, `SALES_VALUE` trên từng dòng sản phẩm trong basket.

3. Giảm giá tại giao dịch
`RETAIL_DISC`, `COUPON_DISC` và `COUPON_MATCH_DISC`.

4. Thuộc tính sản phẩm
Manufacturer, department, brand, commodity, sub-commodity và kích thước sản phẩm.

5. Campaign, coupon và trưng bày
Mã và thời gian campaign; coupon phát hành/redeem; trạng thái `display` và `mailer` theo sản phẩm–cửa hàng–tuần.

6. Thông tin household
Nhóm tuổi, hôn nhân, thu nhập, sở hữu nhà, cấu trúc và quy mô household, nhóm có trẻ em.

Nguồn: Các trường có sẵn trong transaction, product, campaign, coupon, causal và hh_demographic.

Dunnhumby: quy mô và thời gian

Quy mô giao dịch

Chỉ số	Giá trị
Household	2.500
Basket	276.484
Dòng giao dịch	2.595.732
Sản phẩm đã mua	92.339
Cửa hàng	582

Thời gian quan sát

Chỉ số	Giá trị
Số tháng quan sát	24
Basket/tháng (mean)	11.520
Basket/tháng (min–max)	1.897–13.651

Nguồn: EDA từ transaction data.

Dunnhumby: sản phẩm và lịch sử khách hàng

Độ đa dạng sản phẩm

Chỉ số	Giá trị
Department	44
Commodity	308
Sub-commodity	2.383
Manufacturer	6.476
Product size	4.345

Lịch sử theo household

Chỉ số	Min	Median	Mean	Max
Số basket	1	79	110,59	1.300
Tháng hoạt động	1	20	18,11	24
First–last span	0	626	619,48	710

Nguồn: EDA từ transaction và product.

Dunnhumby: coverage và chất lượng dữ liệu

Mức độ lặp lại và coverage

Chỉ số	Tỷ lệ
Household xuất hiện >= 2 lần	99,88%
Hoạt động từ 2 tháng trở lên	99,76%
Entity-month coverage	75,44%

Độ phủ dữ liệu bổ sung

Chỉ số	Coverage
Nhận campaign (1.584 household)	63,36%
Redeem coupon (434 household)	17,36%
Có demographic (801 household)	32,04%

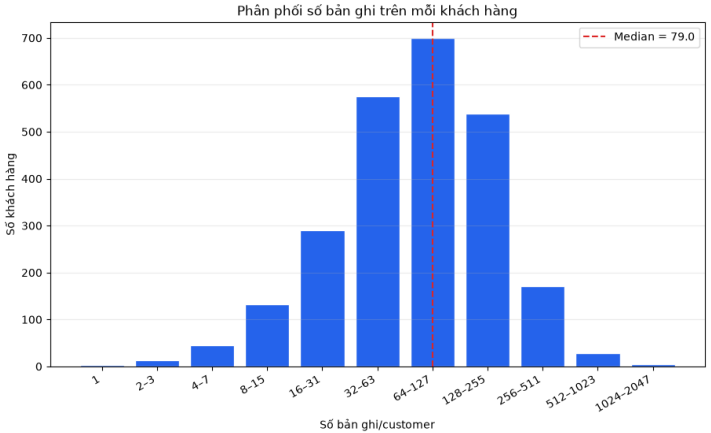
Nguồn: EDA từ 8 bảng CSV.

Dunnhumby: thống kê basket theo household

Ý nghĩa	Kết quả
Số basket nhỏ nhất của một household	1
Trung vị số basket trên mỗi household	79
Trung bình số basket trên mỗi household	110,59
Số basket lớn nhất của một household	1.300

Nguồn: Kết quả từ `describe_entities(basket_events, spec)`.

Dunnhumby: phân phối số basket theo household



79 median basket/household

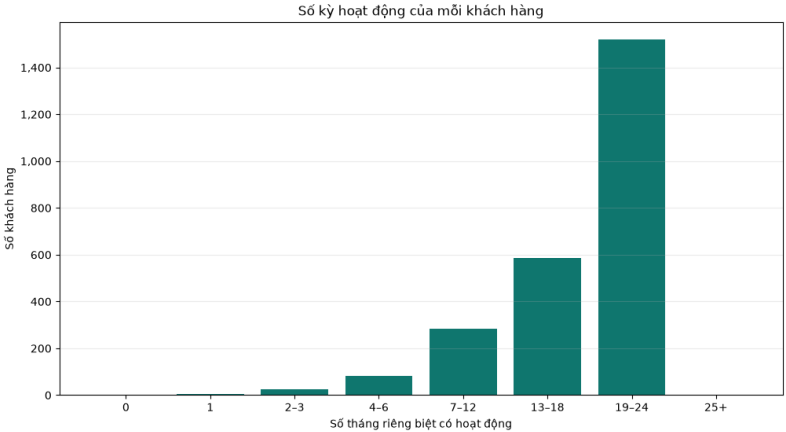
110,59 mean basket/household

1 min

1.300 max

Nguồn: EDA từ 276.484 basket distinct của 2.500 household. Mỗi basket được đếm một lần theo `BASKET_ID`.

Dunnhumby: active_months của mỗi household



active_months là số tháng mà household phát sinh ít nhất một giao dịch.

Nguồn: EDA cục bộ từ basket-level events